



SHIELD AI : Network Attack Detection Model

Détection d'Intrusions Réseau par ML sur NSL-KDD

SIFEDDINE LEGNIOUI ET YOUSSEF SARRAF

ENCADRÉE PAR : OUMAIMA GUENDOUL

MASTER d'Excellence en Intelligence Artificielle



Contexte & Objectifs

Les cyberattaques sont en **constante augmentation**. Les systèmes de détection d'intrusions (IDS) traditionnels à base de signatures peinent à détecter les **menaces nouvelles** et mutantes. L'intégration du **machine learning** permet une détection adaptative et généralisable.

Objectifs du Projet :

- Classifier le trafic en **Normal** vs **Attaque**.
- Identifier les catégories : DoS, Probe, R2L, U2R.
- Comparer les performances de XGBoost & Random Forest.
- Déployer un dashboard interactif en temps réel.

Défis principaux :

- Réduire 38 types d'attaques en 5 grandes classes.
- Gérer le déséquilibre extrême (ex: U2R n'a que 52 exemples).
- Détecter 14 attaques inconnues présentes uniquement dans le test set.

Dataset NSL-KDD

Le dataset NSL-KDD est la version améliorée du benchmark standard KDD Cup 99, résolvant ses problèmes de redondance. Il décrit des connexions réseau avec 41 caractéristiques.

Distribution des classes :

Classe	Train	Test
Normal	67 343	9 711
DoS	45 927	7 458
Probe	11 656	2 421
R2L	995	2 887
U2R	52	67
Total	125 973	22 544

Catégories de Features (41 au total) :

- 9 Basiques** : protocol_type, service, src_bytes...
- 13 Contenu** : logged_in, root_shell, is_guest_login...
- 19 Traffic** : count, serror_rate, error_rate...

Typologie des Attaques

1. Denial of Service (DoS)

Inonde les ressources réseau pour rendre les services indisponibles. *Vecteurs* : neptune, smurf, pod, teardrop.

2. Probe (Exploration)

Collecte d'informations pour cartographier les vulnérabilités. *Vecteurs* : ipsweep, nmap, satan, portsweep.

3. Remote to Local (R2L)

Accès non autorisé depuis une machine distante sans compte. *Vecteurs* : guess_passwd, ftp_write, imap.

4. User to Root (U2R)

Escalade de privilèges depuis un compte utilisateur local vers root. *Vecteurs* : buffer_overflow, rootkit, loadmodule.

▲ DÉFI MAJEUR : DÉSÉQUILIBRE EXTRÊME

1 295× plus d'exemples **Normal** (67 343) que **U2R** (52)

Analyses Visuelles & Performances du Modèle


Random Forest (SMOTE)

Label Réel \ Label Prédit	Normal	DoS	Probe	R2L	U2R
Normal	9,449	67	192	1	2
DoS	1,705	5,650	105	0	0
Probe	602	164	1,655	0	0
R2L	2,760	0	3	120	2
U2R	55	0	0	5	7


XGBoost (SMOTE)

Label Réel \ Label Prédit	Normal	DoS	Probe	R2L	U2R
Normal	9,445	55	207	1	3
DoS	1,084	6,140	236	0	0
Probe	471	166	1,781	3	0
R2L	2,508	0	12	359	6
U2R	39	0	0	6	22


Random Forest — Top 20 Features



XGBoost — Top 20 Features



Architecture du Système



Modèles & Pipeline

Algorithmes ML comparés :

Modèle	Caractéristiques
XGBoost	Modèle de Gradient Boosting très performant pour les données tabulaires complexes.
Random Forest	Méthode ensembliste basée sur le Bagging, robuste au surapprentissage.

Pipeline Anti-Data-Leakage :

- Le sur-échantillonnage (SMOTE) est appliqué **uniquement** sur le set d'entraînement.
- Utilisation de RandomizedSearchCV combiné avec StratifiedKFold (3 folds).
- Sélection basée sur le **Score F1 Macro**, métrique optimale pour des classes fortement déséquilibrées.

Indicateurs Clés (KPIs)

78.95%

Exactitude Globale (XGBoost)

0.6314

Score F1 Macro (XGBoost)

~7 ms

Latence d'inférence par paquet

Résultats Détaillés

Les résultats finaux du modèle **XGBoost** sur l'ensemble de test NSL-KDD (22 544 connexions).

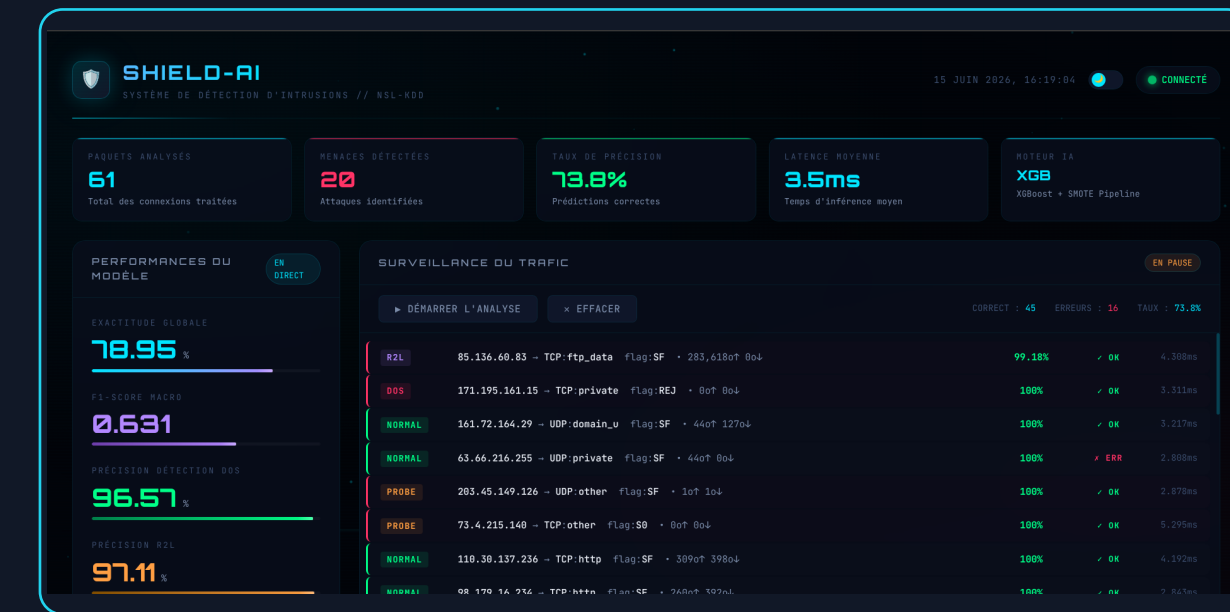
Rapport de Classification :

Classe	Préc.	Rappel	F1	Support
Normal	97.2%	98.1%	97.6%	9 711
DoS	96.6%	98.0%	97.3%	7 458
Probe	89.4%	84.2%	86.7%	2 421
R2L	97.1%	21.5%	0.35	2 887
U2R	71.9%	34.4%	0.46	67

Point critique : le modèle excelle sur **DoS** et **Probe**, mais le rappel R2L chute à **21.5%** malgré 97% de précision – la rareté extrême (995 ex.) limite la généralisation malgré SMOTE.

Dashboard Temps Réel

Nous avons développé une interface web moderne et réactive pour simuler et surveiller le trafic réseau en temps réel.



Fonctionnalités du Dashboard :

- Backend robuste en **FastAPI**.
- Prédiction de flux asynchrones.
- Visualisation des taux d'attaques en direct.
- Solution complètement conteneurisée via **Docker**.

Conclusion & Perspectives

Ce projet démontre l'efficacité de **XGBoost** pour détecter les intrusions réseau classiques. L'intégration de SMOTE a permis d'atténuer le déséquilibre, mais les attaques sophistiquées (U2R) nécessitent des approches différentes.

Perspectives d'évolution :

- Utilisation de modèles séquentiels (**LSTM**) pour capturer l'historique des paquets.
- Mise à l'échelle sur le dataset **CICIDS2017**.
- Déploiement sur matériel Edge (Edge AI).

Sifeddine Legnioui

Sifeddine.legnioui-et@etu.univh2c.ma /in/seif-eddine-legnioui-5990b2297

Youssef Sarraf

youssef.sarraf-et@etu.univh2c.ma /in/youssef-sarraf

