




SHIELD AI : Network Attack Detection Model

Détection d'Intrusions Réseau par ML sur NSL-KDD

SIFEDDINE LEGNIOUI ET YOUSSEF SARRAF

ENCADRÉE PAR : OUMAIMA GUENDOUL

MASTER d'Excellence en Intelligence Artificielle



Contexte & Objectifs

Les cyberattaques sont en **constante augmentation**. Les systèmes de détection d'intrusions (IDS) traditionnels à base de signatures peinent à détecter les **menaces nouvelles** et mutantes. L'intégration du **machine learning** permet une détection adaptative et généralisable.


Objectifs du Projet :

- Classifier le trafic en **Normal** vs **Attaque**.
- Identifier les catégories : DoS, Probe, R2L, U2R.
- Comparer les performances de XGBoost & Random Forest.
- Déployer un dashboard interactif en temps réel.

Défis principaux :

- Réduire 38 types d'attaques en 5 grandes classes.
- Gérer le déséquilibre extrême (ex: U2R n'a que 52 exemples).
- Détecter 14 attaques inconnues présentes uniquement dans le test set.

Architecture du Système



Résultats Détaillés

Les résultats finaux du modèle **XGBoost** sur l'ensemble de test NSL-KDD (22 544 connexions).

Rapport de Classification :

Classe	Préc.	Rappel	F1	Support
Normal	97.2%	98.1%	97.6%	9 711
DoS	96.6%	98.0%	97.3%	7 460
Probe	89.4%	84.2%	86.7%	2 421
R2L	97.1%	21.5%	35.0%	2 885
U2R	71.9%	34.4%	46.0%	67

Point critique : le modèle excelle sur **DoS** et **Probe**, mais le rappel R2L chute à **21.5%** malgré 97% de précision – la rareté extrême (995 ex.) limite la généralisation malgré SMOTE.

Dataset NSL-KDD

Le dataset NSL-KDD est la version améliorée du benchmark standard KDD Cup 99, résolvant ses problèmes de redondance. Il décrit des connexions réseau avec 41 caractéristiques.

Distribution des classes :

Classe	Train	Test
Normal	67 343	9 711
DoS	45 927	7 460
Probe	11 656	2 421
R2L	995	2 885
U2R	52	67
Total	125 973	22 544

Catégories de Features (41 au total) :

- 9 Basiques** : protocol_type, service, src_bytes...
- 13 Contenu** : logged_in, root_shell, is_guest_login...
- 19 Traffic** : count, serror_rate, error_rate...

Modèles & Pipeline

Algorithmes ML comparés :

Modèle	Caractéristiques
XGBoost	Modèle de Gradient Boosting très performant pour les données tabulaires complexes.
Random Forest	Méthode ensembliste basée sur le Bagging, robuste au surapprentissage.

Pipeline Anti-Data-Leakage :

- Le sur-échantillonnage (SMOTE) est appliqué **uniquement** sur le set d'entraînement.
- Utilisation de **RandomizedSearchCV** combiné avec **StratifiedKFold** (3 folds).
- Sélection basée sur le **Score F1 Macro**, métrique optimale pour des classes fortement déséquilibrées.

Indicateurs Clés (KPIs)

78.95%

Exactitude Globale (XGBoost)

0.6314


Score F1 Macro (XGBoost)

~7 ms

Latence d'inférence par paquet

Dashboard Temps Réel

Nous avons développé une interface web moderne et réactive pour simuler et surveiller le trafic réseau en temps réel.



Fonctionnalités du Dashboard :

- Backend robuste en **FastAPI**.
- Prédiction de flux asynchrones.
- Visualisation des taux d'attaques en direct.
- Solution entièrement conteneurisée via **Docker**.



Conclusion & Perspectives

Ce projet démontre l'efficacité de **XGBoost** pour détecter les intrusions réseau classiques. L'intégration de SMOTE a permis d'atténuer le déséquilibre, mais les attaques sophistiquées (U2R) nécessitent des approches différentes.

Perspectives d'évolution :

- Utilisation de modèles séquentiels (**LSTM**) pour capturer l'historique des paquets.
- Mise à l'échelle sur le dataset **CICIDS2017**.
- Déploiement sur matériel Edge (Edge AI).

Analyses Visuelles & Performances du Modèle



Technologies Utilisées

Python 3

Scikit-Learn

XGBoost

FastAPI

Docker

Sifeddine Legnioui

Sifeddine.legnioui-etu@etu.univh2c.ma /in/seif-eddine-legnioui-5990b2297

Youssef Sarraf

youssef.sarraf-etu@etu.univh2c.ma /in/youssef-sarraf

