




SHIELD AI : Network Attack Detection Model

Détection d'Intrusions Réseau par ML sur NSL-KDD

SIFEDDINE LEGNIOUI ET YOUSSEF SARRAF

ENCADRÉE PAR : OUMAÏMA GUENDOUL

MASTER d'Excellence en Intelligence Artificielle



Contexte & Objectifs

Les cyberattaques sont en **constante augmentation**. Les systèmes de détection d'intrusions (IDS) traditionnels à base de signatures peinent à détecter les **menaces nouvelles** et mutantes. L'intégration du **machine learning** permet une détection adaptative et généralisable.

Objectifs du Projet :

- Classier le trafic en **Normal** vs **Attaque**.
- Identifier les catégories : DoS, Probe, R2L, U2R.
- Comparer les performances de XGBoost & Random Forest.
- Déployer un dashboard interactif en temps réel.

Défis principaux :

- Réduire 38 types d'attaques en 5 grandes classes.
- Gérer le déséquilibre extrême (ex: U2R n'a que 52 exemples).
- Détecter 14 attaques inconnues présentes uniquement dans le test set.

Dataset NSL-KDD

Le dataset NSL-KDD est la version améliorée du benchmark standard KDD Cup 99, résolvant ses problèmes de redondance. Il décrit des connexions réseau avec 41 caractéristiques.

Distribution des classes :

Classe	Train	Test
Normal	67 343	9 711
DoS	45 927	7 460
Probe	11 656	2 421
R2L	995	2 885
U2R	52	67
Total	125 973	22 544

Catégories de Features (41 au total) :

- 9 Basiques** : protocol_type, service, src_bytes...
- 13 Contenu** : logged_in, root_shell, is_guest_login...
- 19 Traffic** : count, serror_rate, error_rate...

Typologie des Attaques

1. Denial of Service (DoS)

Inonde les ressources réseau pour rendre les services indisponibles. *Vecteurs* : neptune, smurf, pod, teardrop.

2. Probe (Exploration)

Collecte d'informations pour cartographier les vulnérabilités. *Vecteurs* : ipsweep, nmap, satan, portsweep.



3. Remote to Local (R2L)

Accès non autorisé depuis une machine distante sans compte. *Vecteurs* : guess_passwd, ftp_write, imap.

4. User to Root (U2R)

Escalade de privilèges depuis un compte utilisateur local vers root. *Vecteurs* : buffer_overflow, rootkit, loadmodule.

Analyses Visuelles & Performances du Modèle



Technologies Utilisées

Python 3

Scikit-Learn

XGBoost

FastAPI

Docker

Sifeddine Legnioui

Sifeddine.legnioui-et@etu.univh2c.ma /in/seif-eddine-legnioui-5990b2297

Youssef Sarraf

youssef.sarraf-et@etu.univh2c.ma /in/youssef-sarraf



Résultats Détaillés

Les résultats finaux du modèle **XGBoost** sur l'ensemble de test NSL-KDD (22 544 connexions).


Rapport de Classification :

Classe	Préc.	Rappel	F1	Support
Normal	97.2%	98.1%	97.6%	9 711
DoS	96.6%	98.0%	97.3%	7 460
Probe	89.4%	84.2%	86.7%	2 421
R2L	97.1%	21.5%	35.0%	2 885
U2R	71.9%	34.4%	46.0%	67

Point critique : le modèle excelle sur **DoS** et **Probe**, mais le rappel R2L chute à **21.5%** malgré 97% de précision – la rareté extrême (995 ex.) limite la généralisation malgré SMOTE.

Dashboard Temps Réel

Nous avons développé une interface web moderne et réactive pour simuler et surveiller le trafic réseau en temps réel.



Fonctionnalités du Dashboard :

- Backend robuste en **FastAPI**.
- Prédiction de flux asynchrones.
- Visualisation des taux d'attaques en direct.
- Solution entièrement conteneurisée via **Docker**.

Conclusion & Perspectives

Ce projet démontre l'efficacité de **XGBoost** pour détecter les intrusions réseau classiques. L'intégration de SMOTE a permis d'atténuer le déséquilibre, mais les attaques sophistiquées (U2R) nécessitent des approches différentes.

Perspectives d'évolution :

- Utilisation de modèles séquentiels (**LSTM**) pour capturer l'historique des paquets.
- Mise à l'échelle sur le dataset **CICIDS2017**.
- Déploiement sur matériel Edge (Edge AI).